



教育背景

自动化 (本科)
控制科学与工程 (硕士)

2022.09 - 2026.06
2026.09 - 2029.06

专业技能

- 熟悉 RAG 全链路设计与优化，能够结合业务场景对召回效果、响应质量与系统性能进行针对性优化。
- 熟悉 Agent 基本原理，了解任务规划、工具调用、流程编排等核心机制，掌握 Agent 记忆系统的基础设计思路。
- 熟悉 Claude Code、OpenClaw、Hermes 等 Agent 的使用，了解架构设计原理，能够结合实际场景进行使用与实践。
- 熟悉 Claude Code 的使用流程与常见操作方式，能够利用其完成代码理解、代码修改、任务拆解与开发辅助等工作。
- 熟悉深度学习框架 pytorch，并针对具体业务做出针对性优化。具备计算机视觉领域模型训练，模块优化，微调经验。

项目经历

MiniCode AI应用开发 2025.12 - 2026.04

项目简介：参考 Claude Code 架构设计并实现 AI Coding Agent，基于 Query Loop + Tool Use 构建任务执行闭环，重点设计 Skill 路由、自进化记忆沉淀、分层上下文压缩、多 Agent 协作与权限安全审查等机制，提升复杂任务下的执行准确率、上下文稳定性与推理效率。

技术栈：Agent、Tool Calling、Memory System、Prompt Cache、Claude Code、Hermes、Python

技术亮点：

- Skill 能力体系**：设计 Skill 分层路由系统，将原子 Tool、高层 Skill 与 Skill 目录分层组织，结合任务意图识别、元信息标签、适用边界与示例进行二阶段召回与精排，解决 Skill 自进化增长下的检索噪声、功能重叠、召回空间过大与 Token 成本高问题。
- 自进化记忆沉淀**：设计自进化记忆沉淀机制，将执行过程中的程序性经验、情景记忆、用户画像自动提炼为可复用记忆资产，构建“执行—反思—提炼—分类存储—索引更新—按需复用”的闭环，实现跨会话复用、错误修复加速、skill 能力生长。
- 分层上下文压缩**：设计分层上下文压缩机制，将大工具结果外置化、缓存友好型占位压缩与结构化笔记摘要结合，构建“摘要预览—占位替换—按需检索—超限兜底”的上下文治理闭环，在保证长会话稳定性的同时提升 Prompt Cache 收益并降低 Token 成本。
- 中心化多 Agent 协作**：设计中心化多 Agent 协作架构，以主 Agent 统一规划、审批与质量控制，子 Agent 以 Tool Call 方式受控执行，避免引入复杂的 Agent 间协调与状态管理基础设施；通过不移交控制权、最小化结果传递、工具权限约束与路径边界限制保障安全性，并支持 Fork / Worktree / Agent Team 等协作模式，在高质量、强约束的 Coding 场景下提升并行执行效率与任务稳定性。
- 权限与安全审查**：构建规则过滤、工具自检、AI 风险分类(prompt注入防御)与人工确认的多层审查链路，提升 Agent 在真实开发环境下的可控性与安全性。

面向个人的多模态 RAG 知识库问答系统 AI应用开发 2026.01 - 2026.05

项目简介：面向个人知识管理场景的多模态 RAG 问答系统，支持 PDF、Markdown、图片等常见知识源，围绕离线索引阶段、在线检索阶段、效果测评、增量索引与缓存加速完成全链路工程优化，提升个人知识场景下的问答准确率、系统响应效率。

技术栈：Python、LangChain、Chroma、BM25、RAGAS、OCR、VLM

技术亮点：

- 离线索引优化**：重点优化了复杂 PDF 和 Markdown 的解析流程；针对包含图片的文档，结合 OCR 与 VLM 提取文本和语义信息；同时对切分后的 chunk 进行清洗和元数据绑定，并建立 BM25 与稠密向量的混合索引。
- 在线检索优化**：设计并优化 RAG 在线检索链路，涵盖查询改写、问题路由、多路召回、Rerank 精排、上下文拼装与引用核查机制，并通过低置信度二次检索机制提升召回效果和回答质量。
- 测评与工程性能优化**：基于 RAGAS 测评框架、MRR、Hit 搭建检索与生成联合评估流程，实现对切分策略、召回参数与重排模型的量化分析。
- 增量索引、分层缓存与工厂模式解耦**：设计基于文档 Hash 的增量索引与热更新机制，支持文档新增、修改、删除的快速同步；将文档解析、切块、向量化、查询改写、rerank 等链路解耦为可插拔模块，便于效果对比，通过分层缓存复用 QA 结构及索引结构。